

PHÂN TÍCH CÁC YẾU TỐ ẢNH HƯỞNG VÀ DỰ ĐOÁN GIÁ XE Ô TÔ ĐÃ QUA SỬ DỤNG

Nguyễn Thị Xuân Phương | Lớp K58KTP | MSSV: K225480106054
GVHD: TS. Nguyễn Văn Huy | Khoa Điện tử

Đặt Vấn Đề & Mục Tiêu Nghiên Cứu

Vấn đề: Định giá xe cũ truyền thống dựa trên cảm tính, thiếu minh bạch và chính xác

Giải pháp: Ứng dụng Khoa học dữ liệu và Học máy để định giá khách quan

Mục tiêu: Phân tích 5 câu hỏi nghiên cứu cốt lõi và xây dựng mô hình dự đoán giá xe hiệu quả





Studio Shodwe

Data Pipeline

Quy trình xử lý dữ liệu

Bước 1: CSV thô (used_cars.csv)

Bước 2: Làm sạch dữ liệu (loại bỏ ký tự đặc biệt, xử lý thiếu)

Bước 3: Kỹ nghệ đặc trưng (car_age, milage_per_year)

Bước 4: Phân tích khám phá dữ liệu (EDA)

Bước 5: Học máy (Linear Regression & Random Forest)

→ Kết quả: 3,775 mẫu sạch · 14 thuộc tính



Studio Shodwe



EDA – Câu hỏi 1: Xu hướng Thương hiệu Xe Cũ

Ford dẫn đầu số lượng xe cũ trên thị trường
Các hãng nổi bật: Chevrolet, Toyota, BMW, Honda
Giá bán trung bình cao nhất: Porsche & Land
Rover

Xu hướng: Xe Mỹ phổ biến về số lượng, xe Châu
Âu dẫn đầu về giá



EDA – Câu hỏi 2: Tương quan Milage, Tuổi xe & Giá

Milage & Giá xe

Hệ số tương quan Pearson: $r = -0.636$
→ Tương quan nghịch mạnh: Xe có số dặm chạy càng cao thì giá bán càng thấp.
Xe chạy nhiều dặm bị hao mòn cơ học, giảm tuổi thọ động cơ và các bộ phận, dẫn đến giảm giá trị thị trường đáng kể.

Tuổi xe & Giá xe

Hệ số tương quan Pearson: $r = -0.586$
→ Tương quan nghịch vừa-mạnh: Tuổi xe càng cao thì giá bán càng giảm.
Kết luận: Hai yếu tố hao mòn vật lý – Milage (49%) và Car Age (17%) – quyết định đến 66% giá trị xe cũ trên thị trường.



EDA – Câu hỏi 3: Phân bố Nhiên liệu & Động cơ

Phân bố Loại Nhiên liệu

- Gasoline: ~85% – chiếm ưu thế tuyệt đối
 - E85 Flex Fuel: ~6%
 - Diesel: ~4%
 - Hybrid: ~3%
 - Electric: ~2%
- Xe xăng truyền thống vẫn chiếm đa số trên thị trường xe cũ

Top 5 Cấu hình Động cơ

- 1.4-Cylinder, 2.5L – phổ biến nhất
- 2.6-Cylinder, 3.5L – hiệu suất cao
- 3.4-Cylinder, 2.0L – tiết kiệm nhiên liệu
- 4.8-Cylinder, 5.0L – xe hiệu suất cao
- 5.4-Cylinder, 1.5L – xe đô thị nhỏ gọn
6. → Động cơ 4 xi-lanh chiếm đa số trong phân khúc xe cũ

EDA – Câu hỏi 4: Ảnh hưởng của Tai nạn đến Giá Xe

Xe Không Tai Nạn

Giá trung bình: \$36,657.43
Xe có lịch sử sạch, không ghi nhận va chạm hay tai nạn, giữ nguyên giá trị cao trên thị trường xe cũ.

Xe Có Tai Nạn

Giá trung bình: \$25,100.60
Giảm giá trị 31.53% so với xe không tai nạn. Tai nạn là yếu tố tiêu cực đáng kể, ảnh hưởng trực tiếp đến định giá xe cũ trên thị trường.


EDA – Câu hỏi 5: Phân phối giá và dữ liệu ngoại lai

Histogram – Phân phối giá

- Giá xe tập trung chủ yếu dưới \$100,000
- Phân phối lệch phải (right-skewed), phù hợp quy luật kinh tế tài sản
- Đỉnh phân phối nằm trong khoảng \$15,000 – \$40,000
- Phần đuôi phải kéo dài do các xe hạng sang có giá rất cao

Boxplot – Nhận diện Outliers

- Dữ liệu ngoại lai (outliers) được xác định ở ngưỡng giá rất cao
- Các điểm ngoại lai cần loại bỏ để tránh làm lệch mô hình
- Sau xử lý: dữ liệu phân phối đồng đều hơn, cải thiện độ chính xác
- Kết luận: Tiền xử lý outliers là bước then chốt trong pipeline



Mô hình Học Máy – Phương pháp Thử nghiệm

Linear Regression

Mô hình Baseline đơn giản, dễ diễn giải.

- Giả định mối quan hệ tuyến tính giữa các đặc trưng và giá xe.
- One-Hot Encoding cho biến phân loại (hãng xe, nhiên liệu, v.v.).
- Chia dữ liệu: 80% Train / 20% Test.
- Dùng làm chuẩn so sánh với mô hình nâng cao.

Random Forest Regressor

Mô hình Đề xuất – Ensemble Learning.

- Kết hợp nhiều cây quyết định để tăng độ chính xác.
- Tham số: `max_depth = 15`, chống overfitting hiệu quả.
- One-Hot Encoding đồng nhất với Linear Regression.
- Chia dữ liệu: 80% Train / 20% Test (3,020 / 755 mẫu).





Kết Quả So Sánh Hiệu Năng Mô Hình

Linear Regression

R^2 Score: 73.17%

MAE: ~\$8,500

Mô hình baseline tuyến tính, phù hợp với dữ liệu sau khi loại bỏ outliers. Hiệu suất vượt trội hơn Random Forest trong bộ dữ liệu này.

Random Forest

R^2 Score: 67.75%

MAE: ~\$9,200

Mô hình ensemble với `max_depth=15`. Mặc dù mạnh hơn về lý thuyết, hiệu suất thấp hơn do dữ liệu có tính tuyến tính cao sau tiền xử lý.

Nhận Xét & Kết Luận

Linear Regression cho kết quả tốt hơn do dữ liệu thể hiện mối quan hệ tuyến tính rõ ràng sau khi loại bỏ ngoại lai.

Tiền xử lý dữ liệu đóng vai trò then chốt trong việc nâng cao độ chính xác của cả hai mô hình.


Feature Importance

Milage: 49% tầm quan trọng cao nhất

Car Age: 17% ảnh hưởng đáng kể

Brand, Engine, Fuel Type & Accident

Hai yếu tố hao mòn quyết định 66% giá trị





Studio Shodwe



Cơ sở Lý thuyết

Khoa học dữ liệu: Lĩnh vực khai thác tri thức từ dữ liệu thô bằng thống kê, lập trình và học máy.
Linear Regression: $\hat{y} = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n$ — mô hình baseline tuyến tính đơn giản, dễ diễn giải.
Random Forest: Ensemble nhiều cây quyết định, giảm overfitting, xử lý tốt dữ liệu phi tuyến.
Chỉ số đánh giá: R^2 Score (độ khớp mô hình), MAE (sai số tuyệt đối trung bình).



www.reallygreatsite.com

Công nghệ & Công cụ Sử dụng

Python & Thư viện Dữ liệu

Ngôn ngữ lập trình Python là nền tảng chính. Thư viện Pandas và NumPy được sử dụng để xử lý, làm sạch và biến đổi dữ liệu từ file `used_cars.csv` với 3,775 mẫu và 14 thuộc tính.

Trực quan hóa Dữ liệu

Matplotlib và Seaborn được ứng dụng để xây dựng các biểu đồ cột, biểu đồ phân tán, histogram, boxplot và ma trận tương quan Pearson trong phân tích EDA.

Học máy – Scikit-learn

Thư viện Scikit-learn cung cấp các mô hình Linear Regression và Random Forest Regressor. Hỗ trợ One-Hot Encoding, chia tập Train/Test (80/20) và đánh giá R^2 Score, MAE.

Môi trường – Google Colab

Google Colab là môi trường tính toán đám mây, hỗ trợ GPU miễn phí. Toàn bộ pipeline từ tiền xử lý, EDA đến huấn luyện mô hình được thực thi trên nền tảng này.

Kết Quả Đạt Được

- ✓ Xây dựng pipeline xử lý dữ liệu tự động
- ✓ Giải quyết 5 câu hỏi nghiên cứu EDA
- ✓ Tai nạn làm giảm 31.53% giá trị xe
- ✓ Mô hình dự đoán đạt $R^2 = 73.17\%$
- ✓ Milage là yếu tố quan trọng nhất (49%)





Hướng Phát Triển Tương Lai

1. Tối ưu Feature Encoding

Áp dụng các kỹ thuật mã hóa nâng cao như Target Encoding và Count Encoding thay thế One-Hot Encoding, giúp giảm chiều dữ liệu và cải thiện hiệu năng mô hình với biến phân loại có nhiều giá trị.

1. Thuật toán Tiên tiến

Thử nghiệm các thuật toán Gradient Boosting hiện đại: XGBoost, LightGBM và CatBoost. Các mô hình này có khả năng xử lý dữ liệu phi tuyến tốt hơn và kỳ vọng cải thiện R^2 vượt ngưỡng 80%.

1. Làm giàu Dữ liệu

Bổ sung các thuộc tính giá trị cao: lịch sử bảo dưỡng định kỳ, số lượng chủ sở hữu trước đây, khu vực địa lý giao dịch. Dữ liệu phong phú hơn sẽ nâng cao đáng kể độ chính xác dự đoán.

Kết Luận

01

Hoàn thành mục tiêu

Đã hoàn thành toàn bộ mục tiêu phân tích 5 câu hỏi EDA và xây dựng mô hình dự đoán giá xe cũ đạt $R^2 = 73.17\%$ với Linear Regression.

03

Đóng góp khoa học

Chứng minh vai trò của Data Science trong định giá tài sản; xác định Milage (49%) và Car Age (17%) là hai yếu tố quyết định 66% giá trị xe.

02

Ứng dụng thực tiễn

Hỗ trợ người mua, người bán và doanh nghiệp định giá xe cũ một cách khách quan, minh bạch, thay thế phương pháp cảm tính truyền thống.

04

Bài học cốt lõi

Tiền xử lý dữ liệu là then chốt: "Garbage In, Garbage Out". Chất lượng dữ liệu đầu vào quyết định trực tiếp hiệu năng và độ tin cậy của mô hình học máy.



Khoa Điện tử – ĐHKTCN

Xin cảm ơn!

Mời thầy cô và các bạn đặt câu hỏi & trao đổi

GVHD: TS. Nguyễn Văn Huy | SV: Nguyễn Thị Xuân Phương –
K58KTP

